

基于 CNN 与 SNN 的视觉识别与目标检测建模研究

刘丰源¹ (12313217) 梁家源¹ (12313215)

¹ 南方科技大学系统设计与智能制造学院 系统建模与仿真课程项目

指导教师：陈亮名、尉进 2026 年 5 月

摘要—本文围绕视觉识别与目标检测任务，构建并比较卷积神经网络 (CNN) 与脉冲神经网络 (SNN) 的建模方法。图像识别部分以 MNIST 为数据集，分别实现 CNN 分类器与基于速率编码和 LIF 神经元的 SNN 分类器；目标检测部分以 Pascal VOC 2007 为数据集，采用 Faster R-CNN MobileNetV3-Large FPN 作为 CNN 检测基线，并进一步设计“CNN 候选框生成+SNN ROI 分类”的 SNN 检测框架。实验结果表明，CNN 在静态图像分类和目标检测中具有更高精度和更稳定的训练过程；SNN 通过脉冲编码、膜电位动态和输出层 spike count 能够完成分类与候选区域判别，并提供可解释的脉冲响应图谱。最终，CNN 在 MNIST 测试集上达到 99.06% 准确率，SNN 在 MNIST 测试集上达到 97.73% 准确率；CNN 检测模型在 Pascal VOC 2007 测试集上取得 73.95% 的 mAP@0.5；SNN 检测部分在相同外部测试图像上完成目标类别判别并输出 spike count 热力图。本文的实验验证了 CNN 与 SNN 在视觉建模中的差异、互补性及其工程实现特点。

关键词—卷积神经网络；脉冲神经网络；MNIST；Pascal VOC；目标检测；速率编码；LIF 神经元

I. 引言

A. 研究背景与问题定义

视觉识别与目标检测是机器人感知、智能制造、自动驾驶和智能监控中的核心任务。卷积神经网络 (Convolutional Neural Network, CNN) 通过局部感受野、权值共享和多层非线性变换提取图像空间特征，已成为静态视觉任务中的重要基线模型 [2]。相比之下，脉冲神经网络 (Spiking Neural Network, SNN) 使用离散脉冲序列传递信息，并通过膜电位累积、衰减和阈值触发描述神经元动态，具有事件驱动、稀疏发放和潜在低功耗等特性 [5]。

本文围绕“神经网络对视觉识别和检测的建模”展开实验研究，选取 MNIST 手写数字识别和 Pascal VOC 2007 目标检测作为两个代表性任务。前者用于比较 CNN 与 SNN 在标准分类任务中的精度、收敛过程和外部样本预测能力；后者用于比较 CNN 检测框架与 SNN 候选区域分类框架在多类别目标检测场景中的表现。通过两个任务的联合分析，本文从准确率、训练耗时、模型结构、外部测试效果和脉冲响应可视化等角度讨论 CNN 与 SNN 视觉建模的差异。

B. 研究内容与技术路线

本文的技术路线如表1所示。MNIST 图像识别部分分别实现 CNN 分类器和 SNN 分类器，并在官方测试集与 MNIST-Test 外部测试集上进行评估。Pascal VOC 目标检测部分首先训练 Faster R-CNN MobileNetV3-Large FPN 作为 CNN 检测模型，该方法结合区域候选网络和多尺度特征表达完成目标定位与分类 [3, 4]；随后基于该 CNN 检测器生成候选框，并构建 SNN ROI 分类器，对候选区域进行脉冲编码和类别判别。SNN 检测部分共进行了三版迭代：V1 使用 GT crop 直接训练，V2 引入 proposal-matched ROI 和知识蒸馏，V3 进一步加入 background 类别并作为最终方案。

C. 数据集与评价指标

MNIST 数据集包含 28×28 灰度手写数字图像，共 10 个类别，是图像分类任务中常用的基

表 1: 实验任务与输出内容

任务	模型	核心方法	主要输出
图像识别	CNN	卷积分类器	loss 曲线、测试准确率、外部预测图
图像识别	SNN	速率编码+LIF	spike raster、spike count、外部预测图
目标检测	CNN	Faster R-CNN	mAP、检测框图、误差分析
目标检测	SNN	CNN proposal+SNN ROI 分类	检测图、spike count 热力图

准数据集 [1]。本文将官方训练集划分为训练集和验证集，并使用官方测试集评估模型泛化能力；同时设置 MNIST-Test 外部测试目录，用于逐图验证模型推理结果。Pascal VOC 2007 包含 20 个目标类别及 XML 格式边界框标注 [6]，本文使用其 trainval/test 划分进行 CNN 检测训练与评估，并使用 PascalVOC-Test 中的 3 张外部图像展示检测效果。

图像分类任务主要采用测试准确率、外部测试正确数、训练曲线和预测样例作为评价依据。目标检测任务采用 mAP@0.5 作为 CNN 检测模型的量化指标，其中 IoU 阈值为 0.5，AP 采用 Pascal VOC 2007 的 11-point 计算方式。SNN 相关实验除准确率和外部检测结果外，还重点展示隐藏层 spike raster、输出层 spike count 和 ROI 输出热力图，以体现脉冲神经网络的时序响应特征。

D. 主要结果概览

实验结果表明，CNN 在静态图像任务中具有更高精度和更短训练时间。CNN-MNIST 模型在官方测试集上达到 99.06% 准确率，在外部 10 张图像中正确识别 9 张；SNN-MNIST 模型在官方测试集上达到 97.73% 准确率，在外部 10 张图像中全部识别正确。目标检测部分，CNN 检测模型在 Pascal VOC 2007 测试集上取得 73.95% 的 mAP@0.5。SNN 检测部分最终采用 V3 方案，即基于 CNN 候选框和 21 类 SNN ROI 分类器的检测流程，能够在与 CNN 相同的三张外部图像上输出检测类别和对应的输出层 spike count 热力图。

表 2: MNIST 数据集划分情况

数据集	样本数量	来源	用途
训练集	50000	MNIST 官方训练集划分	模型参数训练
验证集	10000	MNIST 官方训练集划分	模型选择与调参
测试集	10000	MNIST 官方测试集	最终性能评估
外部测试集	10	./MNIST-Test/	独立图像文件预测

II. MNIST 图像识别实验

A. CNN 图像识别模型

1) 数据集划分与预处理

本实验首先基于卷积神经网络 (Convolutional Neural Network, CNN) 完成 MNIST 手写数字图像分类任务。MNIST 数据集中的图像为 28×28 灰度图像, 共包含数字 0 至 9 十个类别。实验使用 MNIST 官方训练集中的 60000 张图像, 并按照固定随机种子将其划分为 50000 张训练图像和 10000 张验证图像; 官方测试集中的 10000 张图像作为最终测试集。因此, 整体数据划分近似满足训练集、验证集、测试集为 5:1:1 的比例要求。

在数据预处理阶段, 首先将输入图像转换为单通道灰度张量, 然后使用 MNIST 数据集常用的均值和标准差进行归一化处理, 归一化参数为均值 $\mu = 0.1307$, 标准差 $\sigma = 0.3081$ 。归一化后的图像输入 CNN 模型进行训练和推理。除官方测试集外, 实验还设置了外部测试目录 ./MNIST-Test/, 该目录与项目中的 external/MNIST-Test/保持一致, 用于保存 10 张待分类手写数字图像, 并检验模型对独立图像文件的预测能力。

2) CNN 网络结构

本实验构建的 CNN 模型记为 CNNMnist, 网络输入为 $1 \times 28 \times 28$ 的单通道灰度图像。模型主体由特征提取模块和分类模块两部分组成。特征提取模块包含两个卷积块, 每个卷积块均由卷积层、ReLU 激活函数和最大池化层组成。第一层卷积将输入通道数由 1 扩展至 32, 卷积核大小为 3×3 , padding 为 1, 因此卷积后特征图空间尺寸保持为 28×28 ; 随后通过 2×2 最大池化将特征图降采样至 14×14 。第二层卷积将通道数由 32 扩展至 64, 同样采用 3×3 卷积核和 padding 为 1 的设置, 再经过最大池化后得到 $64 \times 7 \times 7$ 的特征图。

分类模块首先将卷积特征展平成一维向量, 然后输入全连接层。第一层全连接层将 $64 \times 7 \times 7 = 3136$ 维特征映射到 128 维, 并使用 ReLU 激活函数和 Dropout 抑制过拟合; 最后通过输出层得到 10 维分类结果, 分别对应数字 0 至 9。模型总可训练参数数量为 421642。

3) 训练设置与评价方法

CNN 模型训练采用交叉熵损失函数 (Cross Entropy Loss) 作为分类损失函数, 优化器采用 Adam 优化器。训练学习率设置为 1×10^{-3} , 权重衰减系数设置为 1×10^{-4} , batch size 为 128, 训练轮数为 8。在每一轮训练结束后, 模型都会在验证集上计算验证损失和验证准确率, 并保存验证准确率最高的模型作为最终评估模型。训练结束后, 重新加载最佳模型, 并

表 3: CNN-MNIST 网络结构

网络层	输入尺寸	输出尺寸	参数设置
输入层	$1 \times 28 \times 28$	$1 \times 28 \times 28$	灰度图像
卷积层 1	$1 \times 28 \times 28$	$32 \times 28 \times 28$	3×3 , padding=1
激活层 1	$32 \times 28 \times 28$	$32 \times 28 \times 28$	ReLU
池化层 1	$32 \times 28 \times 28$	$32 \times 14 \times 14$	MaxPool, 2×2
卷积层 2	$32 \times 14 \times 14$	$64 \times 14 \times 14$	3×3 , padding=1
激活层 2	$64 \times 14 \times 14$	$64 \times 14 \times 14$	ReLU
池化层 2	$64 \times 14 \times 14$	$64 \times 7 \times 7$	MaxPool, 2×2
展平层	$64 \times 7 \times 7$	3136	Flatten
全连接层 1	3136	128	ReLU, Dropout=0.3
全连接层 2	128	10	输出 10 类 logits

表 4: CNN-MNIST 训练参数

参数	设置
模型名称	CNNMnist
损失函数	CrossEntropyLoss
优化器	Adam
学习率	1×10^{-3}
权重衰减	1×10^{-4}
Batch size	128
Epoch	8
最佳模型选择标准	验证集准确率最高
训练设备	CUDA
可训练参数量	421642

表 5: CNN-MNIST 分类结果

指标	数值
最佳验证准确率	98.91%
测试集准确率	99.06%
测试集损失	0.0272
训练总时间	12.95 s
可训练参数量	421642

在 10000 张官方测试图像上计算测试损失和测试准确率。

4) 实验结果与分析

CNN 模型在 MNIST 测试集上的最终测试准确率为 99.06%, 测试损失为 0.0272, 最佳验证集准确率为 98.91%。总训练时间为 12.95 s。该结果显著高于项目要求中 CNN 图像识别测试准确率不低于 95% 的要求, 说明所构建的卷积神经网络能够有效提取 MNIST 手写数字图像中的局部边缘、笔画形状和空间结构特征。

图1给出了 CNN 模型在训练集和验证集上的损失变化曲线。从图中可以看出, 训练损失从第 1 轮的 0.2352 快速下降到第 8 轮的 0.0234, 说明模型在训练过程中能够快速学习到有效的图像分类特征。验证损失整体也呈下降趋势, 从第 1 轮的 0.0668 下降到第 7 轮附近的 0.0376, 随后在第 8 轮略有上升, 但整体波动较小, 说明模型没有出现明显过拟合现象。训练损失低于验证损失是正常现象, 主要原因是训练集直接参与参数更新, 而验证集只用于模型泛化性能评估。

图2展示了 CNN 模型在 MNIST 官方测试集上的若干预测样例。结果显示, 大部分样本的预测类别




图 1: CNN-MNIST 训练集与验证集损失曲线

表 6: CNN 对 MNIST-Test 外部测试图像的分类结果

图像文件名	真实类别	预测类别	置信度	是否正确
digit_0.png	0	0	1.0000	正确
digit_1.png	1	1	1.0000	正确
digit_2.png	2	2	1.0000	正确
digit_3.png	3	3	0.6163	正确
digit_4.png	4	4	1.0000	正确
digit_5.png	5	6	0.7006	错误
digit_6.png	6	6	1.0000	正确
digit_7.png	7	7	1.0000	正确
digit_8.png	8	8	1.0000	正确
digit_9.png	9	9	0.9972	正确

与真实标签一致,说明模型能够较好地地区分不同数字类别。对于形状差异明显的数字,如 0、1、2、4、7、9 等,模型预测结果较为稳定;对于书写形态相近或笔画存在歧义的样本,模型仍可能产生错误预测,例如部分数字 5 可能被误判为 6。

5) 外部 MNIST-Test 图像分类结果

为进一步评估模型对独立图像文件的推理能力,本实验使用 `./MNIST-Test/` 目录下的 10 张外部测试图像进行分类。该目录中的图像文件命名为 `digit_0.png` 至 `digit_9.png`,文件名中的数字表示其真实类别。推理阶段,程序首先将外部图像统一转换为灰度图像,并缩放至 28×28 大小,然后执行与训练阶段一致的张量转换和归一化操作。模型输出 10 个类别的 logits 后,通过 softmax 计算类别概率,并取概率最大的类别作为最终预测类别。

外部测试集分类结果如表6所示。CNN 模型在 10 张外部测试图像中正确识别了 9 张,仅将 `digit_5.png` 误识别为数字 6,外部测试正确率为 90%。该结果满足项目要求中 `./MNIST-Test/` 文件夹下 10 张图像至少正确识别 8 张的要求。

图3给出了外部测试图像的预测可视化结果。结果显示,模型对 0、1、2、4、6、7、8、9 等类别给出了较高置信度的正确预测。其中, `digit_3.png` 虽然预测正确,但置信度为 0.6163,低于其他样本,说明该样本的书写形态对模型而言具有一定不确定性。`digit_5.png` 被误判为 6,主要原因可能是该图像下方笔画闭合趋势较明显,与数字 6 的局部结构相似,因此模型在卷积特征匹配时更倾向于将其归为 6 类。

综上, CNN 模型在 MNIST 官方测试集上取得了 99.06% 的分类准确率,在外部 10 张图像上取得了 90% 的正确率,均达到项目要求。实验结果表明,卷积层能够有效提取手写数字中的局部笔画和空间结构特征,池化层能够增强模型对小范围平移和形变的鲁棒性,全连接分类层能够基于高层特征完成稳定的数字类别判别。

B. SNN 图像识别模型

1) 脉冲编码方法

在完成 CNN 图像识别模型后,本实验进一步构建脉冲神经网络 (Spiking Neural Network, SNN) 对 MNIST 手写数字图像进行分类。与 CNN 直接处理连续灰度图像不同, SNN 需要先将静态图像转换为随时间变化的脉冲序列。本实验采用速率编码 (rate coding) 方法,将每个像素的灰度值映射为对应输入神经元在时间窗内产生脉冲的概率。

具体而言, MNIST 图像首先被转换为取值范围在 $[0, 1]$ 之间的张量。设某一像素灰度值为 x , 则该像素对应的输入神经元在每个时间步产生脉冲的概率与 x 成正比。因此,灰度值较高的像素在仿真时间窗内具有更高的脉冲发放频率,而背景区域由于灰度值较低,产生脉冲的概率较小。该编码方式能够将图像的空间灰度信息转换为时间维度上的脉冲活动,从而作为 SNN 的输入。

由于速率编码要求输入像素保持在 $[0, 1]$ 范围内,因此 SNN 实验中仅使用 `ToTensor()` 进行图像张量化处理,没有像 CNN 实验那样进行均值和标准差归一化。实验中设置仿真时间步为 25,即每张输入图像被编码为长度为 25 的脉冲序列。

2) SNN 网络结构

本实验构建的 SNN 模型记为 SNNMnist。模型采用全连接结构与 LIF (Leaky Integrate-and-Fire) 脉冲神经元结合的方式实现分类。网络输入层包含 $28 \times 28 = 784$ 个输入神经元,对应 MNIST 图像中的 784 个像素。输入脉冲首先经过第一层全连接层映射到 1000 维隐藏层,然后输入 LIF 神经元层。隐藏层输出的脉冲继续经过第二层全连接层映射到 10 维输出层,并通过输出层 LIF 神经元产生 10 个类别对应的输出脉冲。

LIF 神经元通过膜电位累积输入电流,当膜电位超过阈值时产生脉冲,并在发放后进行膜电位更新。实验中 LIF 神经元的膜电位衰减参数设置为 $\beta = 0.95$ 。模型在每个时间步都会根据当前输入脉冲更新隐藏层和输出层的膜电位,并记录输出层脉冲。最终分类时,对输出层 10 个类别神经元在全部 25 个时间步内的脉冲数进行累加,将累计脉冲数最大的类别作为预测结果。

本实验中的 SNN 模型没有直接继承 CNN 模型权重,而是使用脉冲输入和输出层 spike count 监督信号进行独立训练。训练损失函数为基于输出层累计脉冲数的交叉熵损失,即将 10 个类别的 spike count 作为分类 logits 输入交叉熵函数。

3) 训练设置与评价方法

SNN 模型使用与 CNN 实验相同的数据划分方式,即 50000 张训练图像、10000 张验证图像和 10000




图 2: CNN-MNIST 在测试集上的预测样例




图 3: CNN 对 MNIST-Test 外部图像的预测结果

表 7: SNN-MNIST 模型参数

参数	设置
模型名称	SNNMnist
编码方式	速率编码
输入神经元数量	784
隐藏层神经元数量	1000
输出神经元数量	10
神经元模型	Leaky Integrate-and-Fire, LIF
膜电位衰减参数	$\beta = 0.95$
仿真时间步	25
是否继承 CNN 权重	否
分类方式	输出层累计 spike count 最大值
可训练参数量	795010

张测试图像。模型训练采用 Adam 优化器，学习率设置为 1×10^{-3} ，权重衰减系数为 1×10^{-4} ，batch size 为 128，训练轮数为 8。每轮训练后，模型在验证集

上计算验证损失和验证准确率，并保存验证准确率最高的模型作为最终评估模型。

与 CNN 不同，SNN 的前向传播包含时间维度。对于每个 batch 的输入图像，首先通过速率编码生成形状为 $T \times B \times 1 \times 28 \times 28$ 的脉冲序列，其中 $T = 25$ 为时间步数， B 为 batch size。模型在每个时间步依次更新隐藏层和输出层 LIF 神经元状态，最后对输出层脉冲进行时间维度累加。评价时，若第 k 个输出神经元的累计脉冲数最大，则预测类别为 k 。

4) SNN 实验结果与分析

SNN 模型在 MNIST 测试集上的最终测试准确率为 97.73%，测试损失为 0.0994，最佳验证准确率为 97.50%。该结果高于项目要求中推荐的 SNN 测试准确率 85%，说明基于速率编码和 LIF 神经元的 SNN 模型能够有效完成 MNIST 手写数字识别任务。

图4给出了 SNN 模型在训练集和验证集上的损失变化曲线。结果显示，训练损失从第 1 轮的 0.3190

表 8: SNN-MNIST 训练参数

参数	设置
损失函数	CrossEntropyLoss on output spike counts
优化器	Adam
学习率	1×10^{-3}
权重衰减	1×10^{-4}
Batch size	128
Epoch	8
最佳模型选择标准	验证集准确率最高
训练设备	CUDA
总训练时间	36.25 s

表 9: SNN-MNIST 分类结果

指标	数值
最佳验证准确率	97.50%
测试集准确率	97.73%
测试集损失	0.0994
训练总时间	36.25 s
可训练参数量	795010
仿真时间步	25




图 4: SNN-MNIST 训练集与验证集损失曲线

快速下降至第 8 轮的 0.0286, 说明模型能够逐渐学习到有效的脉冲分类特征。验证损失整体存在一定波动, 这是 SNN 训练中较常见的现象, 主要原因是速率编码过程具有随机脉冲采样特征, 同时 LIF 神经元的膜电位状态会受到时间步内脉冲分布的影响。尽管验证损失存在波动, 验证准确率最终达到 97.50%, 说明模型仍具有较好的泛化能力。

5) SNN 脉冲活动可视化

为了展示 SNN 的时间动态特征, 本实验记录了隐藏层神经元在仿真时间窗内的脉冲发放情况。图5为隐藏层前 128 个神经元的 spike raster 图, 横轴表示时间步, 纵轴表示隐藏层神经元编号, 图中的每一个点表示对应神经元在某一时间步产生了一次脉冲。该样本真实标签为 7, 模型预测结果也为 7。

从图中可以看出, 隐藏层神经元并不是在所有时间步连续发放, 而是在不同时间步上呈现稀疏的离散脉冲活动。这说明 SNN 通过神经元膜电位累积和阈值触发机制, 将输入图像的灰度模式转化为具有时间结构的脉冲响应。与 CNN 中的连续激活值不同, SNN 隐藏层的中间表示主要由离散 spike 事件构成。

表 10: SNN 对 MNIST-Test 外部测试图像的分类结果

图像文件名	真实类别	预测类别	最大 spike count	置信度	是否正确
digit_0.png	0	0	17	1.0000	正确
digit_1.png	1	1	20	1.0000	正确
digit_2.png	2	2	24	1.0000	正确
digit_3.png	3	3	7	0.7272	正确
digit_4.png	4	4	15	1.0000	正确
digit_5.png	5	5	11	0.9991	正确
digit_6.png	6	6	20	1.0000	正确
digit_7.png	7	7	24	1.0000	正确
digit_8.png	8	8	17	0.9997	正确
digit_9.png	9	9	14	1.0000	正确

图6展示了同一样本在输出层 10 个类别神经元上的累计脉冲数。结果显示, 类别 7 对应的输出神经元累计脉冲数最高, 明显高于其他类别, 因此模型最终将该样本判定为数字 7。类别 3 也产生了少量脉冲, 说明模型对该样本存在一定的类别相似性响应, 但其累计脉冲数远低于类别 7, 因此不影响最终分类结果。

6) 外部 MNIST-Test 图像分类结果

为检验 SNN 模型对独立图像文件的推理能力, 本实验使用 ./MNIST-Test/ 目录下的 10 张外部测试图像进行分类。推理过程与训练阶段保持一致: 首先将外部图像转换为灰度图像并缩放至 28×28 大小, 然后通过速率编码生成 25 个时间步的输入脉冲序列, 最后统计输出层 10 个类别神经元的累计脉冲数, 并将 spike count 最大的类别作为预测结果。

SNN 模型在外部 10 张 MNIST-Test 图像上全部预测正确, 正确率为 100%。其中, digit_3.png 的预测置信度相对较低, 为 0.7272, 其输出层中数字 3 和数字 8 均产生了脉冲响应, 说明该样本在形态上与数字 8 存在一定相似性。其他样本的预测置信度均接近 1, 表明输出层目标类别神经元的累计脉冲数明显高于其他类别。

图7给出了 SNN 模型对外部 MNIST-Test 图像的预测可视化结果。结果显示, SNN 模型能够正确识别 0 至 9 共 10 个类别, 且除数字 3 外, 其余样本均具有较高置信度。与 CNN 外部测试中将 digit_5.png 误判为 6 不同, SNN 模型在该样本上预测为 5, 说明脉冲时间窗内的累计响应在一定程度上增强了该样本的类别区分能力。

综上, SNN 模型在 MNIST 官方测试集上取得了 97.73% 的分类准确率, 在外部 10 张测试图像上取得了 100% 的正确率, 满足项目要求。实验结果表明, 基于速率编码和 LIF 神经元的 SNN 能够通过时间维度上的脉冲累计完成图像分类任务, 同时其隐藏层和输出层脉冲活动能够直观反映模型的事件驱动计算过程。

C. CNN 与 SNN 图像识别结果对比

为了比较 CNN 与 SNN 在 MNIST 图像识别任务中的表现, 本实验从测试准确率、外部测试正确数、参数量、训练时间和建模特点等方面进行对比, 结果如表11所示。

从分类准确率来看, CNN 在 MNIST 官方测试集上的准确率为 99.06%, 高于 SNN 的 97.73%。这说明在传统静态图像分类任务中, CNN 仍具有更强的直接特征提取能力和更稳定的优化表现。CNN 通




图 5: SNN-MNIST 隐藏层神经元 spike raster 图




图 6: SNN-MNIST 输出层 spike count 分类结果

表 11: CNN 与 SNN 图像识别性能对比

模型	测试准确率	外部测试正确数	参数量	训练时间	主要特点
CNN	99.06%	9/10	421642	12.95 s	精度高, 训练稳定, 直接处理静态图像
SNN	97.73%	10/10	795010	36.25 s	采用速率编码和 LIF 神经元, 具有脉冲稀疏性和时间动态

过卷积核在空间维度上提取局部笔画、边缘和结构特征, 能够较好地适应 MNIST 手写数字分类任务。

从外部测试结果来看, CNN 在 10 张 MNIST-Test 图像中正确识别 9 张, SNN 正确识别 10 张。该结果表明, 虽然 SNN 在官方测试集上的整体准确率略低于 CNN, 但在该组外部测试图像上仍表现出较好的分类能力。尤其是对于 `digit_5.png` 样本, CNN 将其误判为 6, 而 SNN 能够正确识别为 5, 说明脉冲时间窗内的累计响应可能对部分具有局部形态歧义的样本具有一定补充作用。

从模型复杂度和训练耗时来看, SNN 模型参数量为 795010, 高于 CNN 的 421642; 训练时间为 36.25 s, 也高于 CNN 的 12.95 s。主要原因是 SNN 模型需要在 25 个时间步内重复进行神经元状态更新和脉冲传播, 其前向传播不仅包含空间特征映射, 还包含时间维度上的膜电位演化。因此, 在普通 GPU 环境下, SNN 的训练和推理开销通常大于结构相近的 CNN。

从建模机制来看, CNN 使用连续激活值进行前

向传播, 训练过程稳定、精度较高, 适合常规静态图像识别任务。SNN 使用离散脉冲表示信息, 神经元只有在膜电位超过阈值时才产生 spike, 因此具有事件驱动和稀疏计算的特点。SNN 的优势在于其更接近生物神经系统的信息处理方式, 并且在神经形态硬件上具有潜在低功耗优势; 不足之处在于需要额外的脉冲编码过程, 模型性能容易受到仿真时间步、脉冲编码方式和神经元参数的影响。

综合来看, CNN 在 MNIST 任务中取得了更高的整体测试准确率和更短的训练时间, 是该静态图像分类任务中的高效基准模型; SNN 虽然准确率略低, 但能够通过速率编码和 LIF 神经元完成有效分类, 并提供可解释的脉冲活动图谱, 体现了脉冲神经网络在时间动态建模和事件驱动计算方面的特点。

III. CNN 目标检测实验

A. Pascal VOC 数据集与预处理

本章使用 Pascal VOC 2007 数据集完成 CNN 目标检测任务。Pascal VOC 2007 是目标检测任务中的经典数据集, 图像中包含多种真实场景目标。数据集共包含 20 个目标类别, 包括 *person*、*dog*、*bicycle*、*car*、*cat* 等类别。在模型训练时, 额外加入背景类, 因此检测模型的输出类别数为 21 类, 即 20 个目标类别加 1 个 background 类别。

Pascal VOC 数据集的图像文件存放在 `JPEGImages` 目录下, 目标标注文件存放在 `Annotations` 目录下。每张图像对应一个 XML 格式的标注文件, 其中包含目标类别名称以及边界框坐标。边界框采用 $[x_{\min}, y_{\min}, x_{\max}, y_{\max}]$ 格式表示。数据读取过程中, 程序解析 XML 标注文件, 提取目标类别、边界框坐标和 `difficult` 标记, 并将输入图像转换为张量后送入检测网络。

本实验采用 Pascal VOC 2007 的 `trainval` 划分作为训练集, 使用 `test` 划分作为评估集。若数据




图 7: SNN 对 MNIST-Test 外部图像的预测结果

表 12: Pascal VOC 目标检测数据设置

项目	设置
数据集	Pascal VOC 2007
目标类别数	20
模型输出类别数	21, 含 background
训练划分	trainval
评估划分	test
图像目录	JPEGImages
标注目录	Annotations
标注格式	XML
边界框格式	$[x_{\min}, y_{\min}, x_{\max}, y_{\max}]$

表 13: CNN 目标检测模型配置

项目	设置
检测模型	Faster R-CNN MobileNetV3-Large FPN
检测框架类型	两阶段目标检测器
Backbone	MobileNetV3-Large
特征融合结构	FPN
候选框生成模块	RPN
检测头	Fast R-CNN RoI Head
输出类别数	21
Anchor 设置	Faster R-CNN 默认 RPN anchor 设置
损失组成	分类损失、边界框回归损失、RPN 目标性损失、RPN 回归损失

集中不存在 `test.txt`, 程序则自动使用 `val` 划分进行评估。本次实验结果中, 评估集为 `test`。

B. 检测模型结构

本实验采用 Faster R-CNN MobileNetV3-Large FPN 作为 CNN 目标检测模型。Faster R-CNN 属于两阶段目标检测框架。第一阶段由区域候选网络 (Region Proposal Network, RPN) 在特征图上生成候选目标区域; 第二阶段通过 RoI Head 对候选区域进行分类和边界框回归, 从而得到最终的目标类别、置信度和预测框位置。

模型的 backbone 采用 MobileNetV3-Large, 并结合 FPN (Feature Pyramid Network) 进行多尺度特征融合。MobileNetV3-Large 具有较轻量的网络结构, 能够在保证检测性能的同时降低计算开销; FPN 则能够利用不同尺度的特征图进行目标检测, 有利于同时检测图像中的大目标和小目标。RPN 部分根据特征图生成候选框, 并预测每个候选框是否包含目标; RoI Head 部分进一步对候选框进行类别分类和边界框坐标修正。

由于 Pascal VOC 共有 20 个目标类别, 本实验将 Faster R-CNN 的分类预测头替换为 21 类输出, 对应 20 个目标类别和 1 个背景类别。训练过程中, 模型损失由多个部分组成, 主要包括 RPN 目标性损失、RPN 边界框回归损失、RoI 分类损失和 RoI 边界框

回归损失。程序将检测模型返回的各项损失相加, 作为总损失进行反向传播和参数更新。

C. 训练设置与评价指标

模型训练采用 SGD 优化器, 学习率设置为 0.005, 动量参数为 0.9, 权重衰减系数为 0.0005。训练 batch size 为 4, 共训练 5 个 epoch。为了促进训练后期收敛, 训练过程中使用 StepLR 学习率调度器, 每 3 个 epoch 将学习率乘以 0.1。每轮训练结束后, 在评估集上计算 mAP 指标, 并保存 mAP 最高的模型作为最终模型。

目标检测性能采用 $mAP@0.5$ 作为评价指标。其中, IoU (Intersection over Union) 用于衡量预测框与真实框之间的重叠程度。当预测框与某个真实框的 IoU 不低于 0.5, 且类别预测正确时, 该预测可视为正确检测。本实验采用 Pascal VOC 2007 中的 11-point AP 计算方式, 先计算每个类别的 Average Precision (AP), 再对有效类别 AP 求平均, 得到最终 mAP。训练代码中使用的评价指标为 $mAP@0.5$, Pascal VOC 2007 11-point AP。

D. 训练结果

模型训练过程中的训练损失和 mAP 变化如表15所示。结果显示, 训练损失从第 1 个 epoch 的 0.7512 下降到第 5 个 epoch 的 0.4726, 整体呈下降趋势, 说明模型在训练过程中逐渐学习到了目标类别和边界框定位信息。mAP 在前 3 个 epoch 附近存在小幅波动, 第 4 个 epoch 达到最高值 0.7395, 第 5 个 epoch 略微下降至 0.7378。因此, 本实验选择第 4 个

表 14: CNN 目标检测训练参数

参数	设置
优化器	SGD
初始学习率	0.005
Momentum	0.9
Weight decay	0.0005
Batch size	4
Epoch	5
学习率调度器	StepLR
Step size	3
Gamma	0.1
评价指标	mAP@0.5
AP 计算方式	Pascal VOC 2007 11-point AP

表 15: CNN 目标检测训练过程

Epoch	训练损失	mAP@0.5
1	0.7512	0.6850
2	0.6087	0.6765
3	0.5646	0.6819
4	0.4794	0.7395
5	0.4726	0.7378

表 16: CNN 目标检测最终结果

指标	数值
最佳 mAP@0.5	73.95%
最佳 epoch	4
最终 epoch mAP@0.5	73.78%
总训练时间	297.19 s
训练集划分	trainval
评估集划分	test

epoch 对应的模型作为最佳检测模型。

最终, CNN 目标检测模型在 Pascal VOC 2007 测试集上的最佳 $mAP@0.5$ 为 73.95%, 总训练时间为 297.19 s。该结果表明, Faster R-CNN MobileNetV3-Large FPN 能够较好地完成 Pascal VOC 2007 上的多类别目标检测任务。

E. PascalVOC-Test 外部图像检测结果

为满足项目要求, 本实验进一步使用 ./PascalVOC-Test/ 目录下的 3 张外部图像进行检测。推理阶段, 程序加载训练过程中保存的最佳模型 `cnn_detection_best.pt`, 对每张图像输出预测框、类别标签和置信度分数。为了减少低置信度误检, 外部测试时设置置信度阈值为 0.5, 仅显示置信度不低于 0.5 的检测结果。检测结果同时保存为带有预测框和类别标签的图像, 以及 CSV 格式的检测结果表。

图8展示了模型在 000258.jpg 上的检测结果。该图像中包含一名人物和一只狗, 模型分别检测出 *person* 和 *dog* 两个目标, 置信度分别为 0.995 和 0.955。检测框位置基本覆盖了目标主体区域, 说明模型能够在自然场景中同时识别不同类别的目标。

图9展示了模型在 000283.jpg 上的检测结果。该

表 17: CNN 在 PascalVOC-Test 上的检测结果列表

图像文件名	检测数量	预测类别	置信度	预测框坐标 $[x_{min}, y_{min}, x_{max}, y_{max}]$
000258.jpg	2	person	0.995	[340.61, 31.55, 498.06, 332.67]
		dog	0.955	[200.19, 121.11, 396.25, 333.00]
000283.jpg	4	person	1.000	[81.64, 16.06, 189.94, 296.99]
		bicycle	0.999	[333.02, 251.82, 437.61, 454.19]
		person	0.998	[333.78, 114.25, 452.18, 424.08]
		bicycle	0.997	[90.22, 147.16, 176.27, 341.22]
000339.jpg	4	person	0.997	[336.18, 91.42, 474.85, 356.35]
		person	0.993	[3.55, 109.46, 218.39, 371.29]
		person	0.976	[201.44, 181.29, 318.43, 369.41]
		person	0.847	[418.03, 177.08, 497.94, 375.00]




图 8: CNN 在 PascalVOC-Test 图像 000258 上的检测结果




图 9: CNN 在 PascalVOC-Test 图像 000283 上的检测结果

图像中包含两名骑行者和两辆自行车, 模型共检测出 4 个目标, 包括 2 个 *person* 和 2 个 *bicycle*。从检测结果可以看出, 模型能够在同一张图像中区分多个实例, 并分别给出对应的类别标签和边界框。

图10展示了模型在 000339.jpg 上的检测结果。该图像中包含多名人物, 模型共检测出 4 个 *person* 目标, 其中三个目标置信度高于 0.97, 右侧局部遮挡的人物置信度为 0.847。该结果表明, 模型对显著人物目标具有较强检测能力, 同时对于边缘区域或被部分遮挡的目标, 置信度会相对降低。




图 10: CNN 在 PascalVOC-Test 图像 000339 上的检测结果

F. 检测误差分析

从外部测试图像的检测结果可以看出, CNN 检测模型能够较准确地识别人物、狗和自行车等典型目标, 并给出较高置信度的检测结果。然而, 目标检测任务相比图像分类更复杂, 模型不仅需要判断目标类别, 还需要准确预测目标在图像中的位置, 因此仍可能出现以下几类误差。

首先是定位偏差。对于姿态复杂或被遮挡的目标, 预测框可能无法完全贴合目标边界。例如在 000339.jpg 中, 右侧人物只露出部分身体和脸部, 模型虽然能够检测出该人物, 但边界框覆盖区域相对宽泛, 说明遮挡会增加定位难度。

其次是多目标场景下的实例区分问题。在 000283.jpg 中, 两名骑行者和两辆自行车存在明显空间重叠, 人物腿部、自行车车架和背景阴影混合在一起。模型虽然正确检测出两个 person 和两个 bicycle, 但在这类场景下, 人物框和自行车框容易相互重叠, 检测结果对候选框筛选和非极大值抑制较为敏感。

再次是类别混淆问题。Pascal VOC 中的部分类别在局部纹理或形状上具有相似性, 例如 dog、cat 等动物类别, 或 bicycle、motorbike 等轮式交通工具类别。当图像中目标尺度较小、姿态异常或遮挡严重时, 模型可能会将相似类别混淆。

最后是漏检和误检问题。对于小目标、远处目标或边缘区域目标, 特征图中的目标信息较弱, 模型可能出现漏检; 对于背景中与目标形状相似的区域, 模型可能产生误检。本实验在外部测试阶段设置置信度阈值为 0.5, 能够过滤部分低置信度误检, 但过高的阈值也可能导致低置信度真实目标被漏检。因此, 实际应用中需要根据检测任务对准确率和召回率的要求合理选择置信度阈值。

综上, Faster R-CNN MobileNetV3-Large FPN 在 Pascal VOC 目标检测任务中取得了 73.95% 的 $mAP@0.5$, 并能够在外部测试图像中完成多类别、多实例目标检测。其主要优势在于两阶段检测框架具有较好的候选区域筛选和边界框回归能力; 不足之处在于模型推理流程相对复杂, 对于遮挡目标、小目标和类别相似目标仍可能产生定位偏差、类别混淆或漏检问题。

IV. SNN 目标检测实验

A. 总体设计思路

在 CNN 目标检测实验中, Faster R-CNN MobileNetV3-Large FPN 已经能够较好地完成候选框生成和边界框回归。考虑到目标检测任务同时包含目标定位和类别识别两个子任务, 而直接使用 SNN 完成完整边界框回归难度较高, 本实验将 SNN 目标检测建模为“CNN 候选框生成 + SNN 候选区域分类”的两阶段流程。

具体而言, 首先使用训练好的 CNN 检测模型对输入图像生成候选框; 然后根据候选框裁剪 ROI 区域; 接着将 ROI 图像转换为脉冲序列; 最后输入 SNN ROI 分类器, 利用输出层累计 spike count 判断候选区域所属类别。该方法保留了 CNN 检测器在目标定位方面的优势, 同时将目标类别判别部分交由 SNN 完成, 从而能够展示 SNN 在目标检测任务中的脉冲编码、时序推理和输出层 spike 响应。

整体流程可以表示为:

$$I \xrightarrow{\text{Faster R-CNN}} \{B_i, P_i\} \xrightarrow{\text{ROI Crop}} R_i \xrightarrow{\text{Rate Coding}} S_i(t) \xrightarrow{\text{LIF-SNN}} C_i. \quad (1)$$

其中, I 表示输入图像, B_i 表示第 i 个候选框, P_i 表示 CNN 候选框置信度, R_i 表示裁剪后的 ROI 图像, $S_i(t)$ 表示经过速率编码得到的脉冲序列, C_i 表示 SNN 最终预测类别。

B. 三版模型迭代概述

SNN 目标检测部分共进行了三版迭代。三版模型的主要差异不在于是否使用 CNN 候选框, 而在于 ROI 训练样本的构建方式、是否引入 ANN teacher、是否包含 background 类别, 以及 SNN 训练策略是否充分利用蒸馏信息。

第 1 版直接使用 Pascal VOC 真实标注框裁剪目标区域, 并训练 20 类 SNN ROI 分类器。该方法实现简单, 但训练样本主要是较干净的 GT crop, 而外部推理阶段的 ROI 来自 CNN 检测器产生的 proposal crop, 两者存在明显分布差异。因此, 第 1 版在外部检测时容易出现类别混淆。

第 2 版针对第 1 版的分布差异问题, 引入 proposal-matched ROI 数据集。该数据集由 CNN 检测器生成候选框, 并根据 IoU 与真实框匹配, 使训练阶段的 ROI 样本更接近推理阶段的候选区域。同时, 第 2 版先训练 ANN ROI teacher, 再通过 ANN-to-SNN 初始化和知识蒸馏训练 SNN ROI 分类器。第 2 版在 ROI 验证准确率上取得了三版中较高的结果, 但由于只包含 VOC 20 个前景类别, 没有 background 类, 因此面对背景区域或低质量 proposal 时仍可能产生前景误判。

第 3 版在第 2 版基础上进一步加入 background 类别, 将 ROI 分类任务扩展为 21 类, 即 background 加 VOC 20 个目标类别。第 3 版数据集同时包含 GT 真实框、高 IoU 正 proposal 和低 IoU background proposal, 使模型能够在推理阶段过滤被 SNN 判定为背景的候选框。虽然第 3 版 ROI 验证准确率略低




图 11: 第 1 版 SNN ROI 分类器训练与验证损失曲线




图 13: 第 2 版 ANN ROI teacher 训练准确率曲线



图 12: 第 1 版 SNN 在 PascalVOC-Test 图像 000258 上的检测结果

于第 2 版，但其外部三张 PascalVOC-Test 图像的检测结果更稳定，因此本文最终采用第 3 版作为 SNN 目标检测主结果。

C. 第 1 版模型: GT Crop 直接训练

第 1 版模型使用 Pascal VOC 真实标注框直接裁剪目标区域，构建 20 类 VOC 目标 ROI 分类数据集。每个 ROI 经过缩放后输入 SNN 分类器。SNN 结构由两层卷积层和两层全连接层组成，每个卷积层或全连接层后接 LIF 神经元。输入 ROI 首先通过速率编码转换为脉冲序列，然后在多个时间步内输入 SNN，最终根据输出层 20 个类别神经元的累计 spike count 进行分类。

第 1 版模型的优点是流程较直接，能够快速验证“ROI 图像脉冲编码 + SNN 分类”的可行性。但该版本存在一个关键问题：训练阶段使用的 ROI 来自真实标注框，边界较准确、目标居中程度较高；而外部推理阶段的 ROI 来自 CNN 检测器产生的 proposal，可能包含定位偏移、背景干扰或目标裁剪不完整。因此，训练 ROI 和推理 ROI 之间存在分布差异，导致模型在外部检测时容易发生类别误判。

图11展示了第 1 版 SNN ROI 分类器的训练与验证损失曲线。结果显示，训练损失持续下降，但验证损失在后期上升，说明模型对训练集 ROI 逐渐拟合，但泛化能力不足。图12展示了第 1 版在 000258.jpg 上的外部检测结果。虽然模型沿用了 CNN 检测器给出的候选框位置，但将图像中的 dog 目标误判为 bottle，说明第 1 版对外部 proposal crop 的类别判别仍不稳定。

D. 第 2 版模型: Proposal-Matched ROI 与知识蒸馏

第 2 版模型是 SNN 目标检测中的关键改进版本。针对第 1 版训练 ROI 和推理 ROI 分布不一致的问题，第 2 版首先使用训练好的 Faster R-CNN 检测模型作为 proposal generator，对 Pascal VOC 图像生成候选框。随后，将候选框与真实标注框计算 IoU，当候选框与某一真实框的 IoU 不低于 0.50 时，该候选框被保留，并赋予对应真实目标的类别标签。除此之外，第 2 版还保留 GT box 样本，从而使 ROI 数据集同时包含真实标注框和 CNN 候选框。

这种 proposal-matched ROI 数据集能够使训练阶段的 ROI 更接近外部检测阶段的候选区域，缓解第 1 版中的分布差异问题。第 2 版训练集中共生成 17902 个 ROI 样本，其中 7844 个来自 GT box，10058 个来自 proposal；验证集中共生成 17672 个 ROI 样本，其中 7818 个来自 GT box，9854 个来自 proposal。

在训练策略上，第 2 版没有直接从随机初始化开始训练 SNN，而是先训练一个 ANN ROI teacher。该 teacher 网络使用连续激活函数完成 20 类 VOC 目标 ROI 分类，结构上与后续 SNN ROI 分类器保持一致，便于将 ANN 权重迁移到 SNN 中。ANN teacher 训练 25 个 epoch，使用 AdamW 优化器，学习率为 1×10^{-3} ，并使用类别权重和 label smoothing 缓解类别不平衡问题。最终 ANN teacher 在验证集上的最佳准确率达到 61.52%，说明连续值 ANN 模型能够较好地学习 proposal ROI 的类别特征。

随后，第 2 版将 ANN teacher 中的卷积层和全连接层权重迁移到 SNN ROI 分类器中，并采用知识蒸馏继续训练 SNN。SNN 输入采用速率编码，仿真时间步为 25，LIF 神经元膜电位衰减参数为 $\beta = 0.95$ 。训练损失由输出 spike count 的交叉熵损失和 teacher-student 蒸馏损失组成，其中蒸馏温度为 2.0，蒸馏权重为 0.50。通过这种方式，SNN 不仅学习真实类别标签，也学习 ANN teacher 输出类别分布中的软信息。

图13展示了第 2 版 ANN ROI teacher 的训练准确率变化。结果显示，ANN teacher 的训练准确率持续上升，验证准确率最终稳定在 60% 左右，说明 proposal-matched ROI 数据集能够提供有效训练信号。图14展示了第 2 版 SNN student 的蒸馏训练过程。SNN student 经过 ANN 初始化和知识蒸馏后，最佳验证准确率达到 50.36%，相比第 1 版直接训练 SNN 有明显提升。

表 18: SNN 目标检测模型迭代对比

版本	ROI 数据构建方式	类别数	训练策略	主要特点
V1	GT object crop	20	直接训练 SNN ROI 分类器	实现简单, 但训练 ROI 与推理 ROI 分布不一致。
V2	proposal-matched ROI	20	ANN teacher + ANN-to-SNN 初始化 + 知识蒸馏	ROI 验证准确率较高, 但缺少 background 类。
V3	GT crop + 正 proposal + background proposal	21	ANN teacher + SNN 蒸馏 + background 过滤	最终采用, 外部检测结果更稳定。

表 19: 第 2 版 proposal-matched ROI 数据集构成

数据划分	图像数量	ROI 总数	GT 样本数	Proposal 样本数
Train	2501	17902	7844	10058
Val	2510	17672	7818	9854

表 20: 第 2 版 ANN teacher 与 SNN student 训练结果

模型	最佳验证准确率	训练时间
ANN ROI Teacher V2	61.52%	441.07 s
SNN ROI Student V2	50.36%	397.34 s




图 14: 第 2 版 SNN ROI student 蒸馏训练准确率曲线

图15展示了第 2 版模型在 000258.jpg 上的检测结果。与第 1 版相比, 第 2 版能够较稳定地识别 person 目标, 但仍将 dog 误判为 cat。该现象说明, 第 2 版虽然通过 proposal-matched ROI 和知识蒸馏提高了 ROI 分类性能, 但由于其输出类别只有 VOC 20 个前景类别, 没有显式 background 类别, 因此面对复杂 ROI、背景干扰或动物类别相似性时, 仍然可能发生错误分类。

因此, 第 2 版的意义在于验证了 proposal-matched ROI 训练和 ANN-to-SNN 蒸馏对 SNN 目标检测分类器的有效性; 而第 3 版则在此基础上进一步加入 background 类别, 使 ROI 分类任务更符合真实目标检测推理流程。

E. 第 3 版模型: 加入 Background 的最终方案

第 3 版模型在第 2 版基础上继续改进, 将 ROI 分类任务由 20 类前景分类扩展为 21 类分类, 即 background 加 VOC 20 个目标类别。该改进的动机是: 在真实检测推理阶段, CNN proposal generator 可能产生背景候选框或低质量候选框, 如果 SNN 分类器没



图 15: 第 2 版 SNN 在 PascalVOC-Test 图像 000258 上的检测结果

表 21: 第 3 版 ROI 数据集构成

数据划分	图像数量	GT 样本数	正 proposal 样本数	Background 样本数
Train	2501	7844	8899	4701
Val	2510	7818	8644	4868

有 background 输出, 这些候选框只能被强制分配到某个前景类别, 从而增加误检风险。加入 background 类别后, SNN 能够将部分无效候选框判定为背景, 并在最终检测结果中进行过滤。

第 3 版 ROI 数据集由三类样本组成: 第一类为 Pascal VOC 原始标注框, 即 GT crop; 第二类为 CNN 检测器生成并与真实框 IoU 不低于 0.60 的正 proposal; 第三类为与所有真实框 IoU 低于 0.30 的 background proposal。候选框置信度阈值设为 0.05, 每张图像最多保留 80 个 proposal, 每张图像最多采样 8 个 background proposal。所有 ROI 区域裁剪后统一缩放为 64×64 大小, 并设置 padding ratio 为 0.15, 以保留候选框周围的上下文信息。

训练集中共包含 2501 张图像, 对应 7844 个 GT 样本、8899 个正 proposal 样本和 4701 个 background 样本。验证集中共包含 2510 张图像, 对应 7818 个 GT 样本、8644 个正 proposal 样本和 4868 个 background 样本。

F. 第 3 版 SNN ROI 分类器结构

第 3 版 SNN ROI 分类器记为 SNNRoiStudentV3。输入为经过速率编码后的 ROI 脉冲序列, ROI 图像尺寸为 $3 \times 64 \times 64$ 。网络包含三个卷积层和两个全连接层, 每个卷积层或全连接层后接 LIF 神经元。卷积特征经过池化和自适应平均池化后输入全连接层, 最后输出 21 个类别神经元的脉冲响应。

表 22: 第 3 版 SNN ROI 分类器结构

网络层	输入尺寸	输出尺寸	说明
输入 ROI	$3 \times 64 \times 64$	$3 \times 64 \times 64$	ROI 图像
Rate Coding	$3 \times 64 \times 64$	$T \times 3 \times 64 \times 64$	速率编码
Conv1 + LIF	$3 \times 64 \times 64$	$32 \times 64 \times 64$	卷积脉冲特征
MaxPool1	$32 \times 64 \times 64$	$32 \times 32 \times 32$	下采样
Conv2 + LIF	$32 \times 32 \times 32$	$64 \times 32 \times 32$	卷积脉冲特征
MaxPool2	$64 \times 32 \times 32$	$64 \times 16 \times 16$	下采样
Conv3 + LIF	$64 \times 16 \times 16$	$128 \times 16 \times 16$	高层特征
AdaptiveAvgPool	$128 \times 16 \times 16$	$128 \times 4 \times 4$	自适应池化
FC1 + LIF	2048	512	隐藏层脉冲特征
FC2 + LIF	512	21	输出类别 spike

模型结构如下：第一层卷积将通道数由 3 扩展到 32，第二层卷积将通道数由 32 扩展到 64，第三层卷积将通道数由 64 扩展到 128。随后通过自适应平均池化得到 $128 \times 4 \times 4$ 的特征图，并经过全连接层映射到 512 维隐藏特征，最后输出 21 维类别结果。每个时间步内，LIF 神经元根据输入电流更新膜电位，当膜电位超过阈值时产生 spike。经过全部时间步后，输出层各类别神经元的 spike count 被累加，累计脉冲数最高的类别作为 SNN 预测结果。

G. 第 3 版训练方法

第 3 版模型继续采用 ANN teacher 辅助训练。首先训练一个与 SNN 结构对应的 ANN ROI teacher，用连续激活函数完成 21 类 ROI 分类；然后将 ANN 中的卷积层和全连接层权重复制到 SNN 模型中，作为 SNN 初始权重。这样可以缓解 SNN 从随机初始化开始训练时收敛困难的问题。

SNN 训练阶段采用速率编码，将 ROI 图像转换为长度为 30 的脉冲序列。LIF 神经元膜电位衰减参数设为 $\beta = 0.95$ 。损失函数由三部分组成：基于输出层 spike count 的交叉熵损失、ANN teacher 与 SNN 输出之间的知识蒸馏损失，以及基于输出层平均膜电位的辅助分类损失。整体损失函数为：

$$\mathcal{L} = (1 - \alpha)\mathcal{L}_{CE} + \alpha\mathcal{L}_{KD} + \lambda\mathcal{L}_{mem}, \quad (2)$$

其中， $\alpha = 0.75$ ，蒸馏温度为 4.0，膜电位辅助损失权重 $\lambda = 0.10$ 。优化器采用 AdamW，学习率为 3×10^{-4} ，权重衰减为 1×10^{-4} ，batch size 为 64，训练 15 个 epoch。训练前 3 个 epoch 冻结卷积层进行 warm-up，第 4 个 epoch 后解冻全部 SNN 层进行联合优化。

H. 第 3 版训练结果与分析

ANN teacher 在第 3 版 ROI 数据集上的最佳验证准确率为 49.94%，最终非背景类别验证准确率为 52.79%。在此基础上训练得到的 SNN ROI 分类器最佳验证准确率为 46.62%，最终验证准确率为 46.54%，最终非背景类别验证准确率为 47.09%，总训练时间为 618.76 s。由于 SNN 模型需要在 30 个时间步内进行脉冲传播，并且训练时使用多项损失进行蒸馏优化，因此训练时间明显长于普通 ANN ROI 分类器。

图16和图17分别展示了第 3 版 SNN ROI 分类器的训练损失和验证准确率变化。结果显示，训练损失从第 1 轮的 2.6570 下降到第 15 轮的 0.8226，说

表 23: 第 3 版 SNN 目标检测训练参数

参数	设置
最终模型	SNNRoiStudentV3
检测框架	CNN proposal generator + SNN ROI classifier
类别数	21, 含 background
ROI 尺寸	64×64
Padding ratio	0.15
编码方式	Rate coding
仿真时间步	30
LIF 衰减参数	$\beta = 0.95$
优化器	AdamW
学习率	3×10^{-4}
Weight decay	1×10^{-4}
Batch size	64
Epoch	15
蒸馏权重 α	0.75
蒸馏温度	4.0
膜电位辅助损失权重	0.10

表 24: 第 3 版 SNN 目标检测模型训练结果

指标	数值
ANN teacher 最佳验证准确率	49.94%
ANN teacher 最终非背景准确率	52.79%
SNN 最佳验证准确率	46.62%
SNN 最终验证准确率	46.54%
SNN 最终非背景准确率	47.09%
SNN 训练时间	618.76 s




图 16: 第 3 版 SNN ROI 分类器训练与验证损失曲线




图 17: 第 3 版 SNN ROI 分类器训练与验证准确率曲线

明 SNN 模型在训练过程中逐渐学习到 ROI 区域的类别特征。验证准确率从第 1 轮的 33.99% 提升到最高 46.62%，整体呈上升趋势，但后期提升幅度较小，说明 ROI 分类任务本身具有较高难度，且 SNN 脉冲编码和离散发放机制会带来额外的信息损失。

表 25: SNN 在 PascalVOC-Test 上的检测结果列表

图像文件名	检测编号	最终类别	SNN 置信度	候选框坐标 $[x_{min}, y_{min}, x_{max}, y_{max}]$
000258.jpg	det0	person	0.654	[340.61, 31.55, 498.06, 332.67]
	det1	dog	0.606	[200.19, 121.11, 396.25, 333.00]
000283.jpg	det0	person	0.714	[81.64, 16.06, 189.94, 296.99]
	det1	bicycle	0.976	[333.02, 251.82, 437.61, 454.19]
	det2	person	0.962	[333.78, 114.25, 452.18, 424.08]
	det3	bicycle	0.971	[90.22, 147.16, 176.27, 341.22]
000339.jpg	det0	person	0.746	[336.18, 91.42, 474.85, 356.35]
	det1	person	0.396	[3.55, 109.46, 218.39, 371.29]
	det2	person	0.659	[201.44, 181.29, 318.43, 369.41]
	det3	person	0.868	[418.03, 177.08, 497.94, 375.00]




图 18: SNN 在 PascalVOC-Test 图像 000258 上的检测结果

I. PascalVOC-Test 外部图像检测结果

为了与 CNN 目标检测结果保持一致, SNN 目标检测同样使用 ./PascalVOC-Test/ 目录下的三张图像进行测试。推理阶段首先加载训练好的 Faster R-CNN 模型生成候选框, 候选框阈值设为 0.5, 最多保留 10 个检测框。随后将每个候选框裁剪为 ROI 图像, 并使用 SNN ROI 分类器进行类别判断。为了降低速率编码随机性的影响, 每个 ROI 重复进行 5 次脉冲采样和推理, 并对输出 spike count 取平均。若 SNN 预测为 background, 则该候选框不在最终图像中显示。

SNN 外部检测结果如表25所示。结果显示, 在 000258.jpg 中, 模型检测出 person 和 dog 两个目标; 在 000283.jpg 中, 模型检测出两名 person 和两辆 bicycle; 在 000339.jpg 中, 模型检测出四个 person 目标。与 CNN 目标检测结果相比, SNN 目标检测保留了相同的候选框位置, 但类别由 SNN 输出层 spike count 决定。

图18展示了 SNN 模型在 000258.jpg 上的检测结果。模型正确识别出右侧人物和中间的狗。与第 2 版中将 dog 误判为 cat 相比, 第 3 版能够将该目标识别为 dog, 说明加入 background 样本和改进 ROI 训练集后, SNN 对外部图像的分类判别更加稳定。

图19展示了 SNN 模型在 000283.jpg 上的检测结果。图中包含两名骑行者和两辆自行车, 模型分别识别出 person 和 bicycle 类别。其中两个 bicycle 目标的 SNN 置信度分别为 0.976 和 0.971, 说明输出层中 bicycle 类别神经元的累计脉冲数明显高于其他类别。

图20展示了 SNN 模型在 000339.jpg 上的检测结果。模型检测出四个 person 目标, 其中左侧人物的 SNN 置信度为 0.396, 低于其他目标。这主要是因为




图 19: SNN 在 PascalVOC-Test 图像 000283 上的检测结果



图 20: SNN 在 PascalVOC-Test 图像 000339 上的检测结果

该目标姿态较特殊, 且与背景和沙发区域存在较多重叠, 使 ROI 分类难度增加。

J. 输出层脉冲响应分析

为了展示 SNN 在目标检测任务中的脉冲输出特征, 本实验保存了三张外部测试图像中各检测 ROI 的输出层 spike count 热力图。热力图横轴为 21 个类别, 纵轴为不同检测 ROI, 颜色越亮表示该类别输出神经元在仿真时间窗内累计脉冲数越高。

图21展示了 000258.jpg 中两个 ROI 的输出层 spike count。对于 person ROI, person 类别对应的输出脉冲响应较高; 对于 dog ROI, dog 类别输出响应最高, 因此模型最终分别预测为 person 和 dog。

图22展示了 000283.jpg 中四个 ROI 的输出层脉冲响应。结果显示, 对于自行车 ROI, bicycle 类别神经元具有明显更高的 spike count; 对于人物 ROI, person 类别响应最强。该结果表明 SNN 能够通过输出层脉冲累计完成多实例目标类别判别。

图23展示了 000339.jpg 中四个 person ROI 的输出层脉冲响应。多数 ROI 在 person 类别上具有较高响应, 但不同 ROI 之间的响应强度存在差异, 说




图 21: SNN 在图像 000258 上的输出层 spike count 热力图




图 22: SNN 在图像 000283 上的输出层 spike count 热力图

明遮挡、姿态和背景干扰会影响 SNN 输出层 spike count 分布。

K. 误差与局限性分析

虽然第 3 版 SNN 目标检测模型在外部三张图像上的类别预测较为稳定, 但该方法仍存在一定局限。首先, 本实验中的 SNN 主要负责 ROI 分类, 候选框位置仍由 CNN 检测器生成, 因此 SNN 部分并没有独立完成完整的边界框回归。换言之, 该方法更准确地说是在基于 CNN 候选框的 SNN 目标区域分类检测框架, 而不是完全端到端的 SNN 检测器。

其次, SNN ROI 分类准确率低于 CNN 检测模型的整体检测表现。原因在于 Pascal VOC 目标类别复杂, ROI 样本中存在尺度变化、遮挡、背景干扰和类别不平衡等问题; 同时, 速率编码将连续图像转换为随机脉冲序列, 可能造成部分细节信息损失。虽然本实验通过多次脉冲采样平均降低了随机性, 但 SNN 分类仍然会受到仿真时间步和脉冲发放稀疏性的影响。

最后, background 类的加入提高了模型对背景 proposal 的抑制能力, 但也使分类任务从 20 类扩展到 21 类, 训练难度进一步增加。从训练结果可以看出, SNN 最终非背景验证准确率为 47.09%, 略高于整体验证准确率 46.54%, 说明模型对真实目标类别仍具有一定判别能力, 但对于复杂 ROI 仍存在提升空间。

综上, 本实验实现了基于 CNN 候选框和 SNN ROI 分类器的目标检测流程。模型能够在与 CNN 检测相同的 PascalVOC-Test 图像上输出检测框、类别标签和输出层 spike count 热力图, 展示了 SNN 在目标检测任务中的脉冲编码和事件驱动分类过程。相

表 26: 主要实验结果汇总

任务	模型	核心指标	外部测试结果	说明
MNIST 分类	CNN	99.06%	9/10	精度最高, 训练稳定
MNIST 分类	SNN	97.73%	10/10	具有脉冲响应可视化
VOC 检测	CNN	mAP@0.5=73.95%	3 张检测图	完整检测框架
VOC 检测	SNN	ROI Acc.=46.62%	3 张检测图	CNN proposal + SNN 分类

比 CNN 检测模型, SNN 检测模型的优势在于能够提供离散脉冲响应和时间动态解释; 不足之处在于分类精度较低, 且完整检测框定位仍依赖 CNN proposal generator。

V. 实验对比与讨论

A. 整体实验结果

本文围绕 MNIST 图像识别和 Pascal VOC 目标检测任务完成了 CNN 与 SNN 模型构建。整体结果如表26所示。CNN-MNIST 取得 99.06% 测试准确率, SNN-MNIST 取得 97.73% 测试准确率, 两者均满足项目对图像识别任务的要求。目标检测方面, CNN 检测模型在 Pascal VOC 2007 测试集上取得 73.95% 的 mAP@0.5; SNN 检测模型采用 CNN 候选框生成与 SNN ROI 分类相结合的形式, 在外部测试图像上输出目标类别、检测框和输出层 spike count 热力图。

B. CNN 与 SNN 图像识别对比

在 MNIST 图像识别任务中, CNN 的测试准确率高於 SNN, 且训练时间更短。CNN 直接处理归一化后的静态图像, 卷积层能够有效提取数字笔画、边缘和局部结构, 因此在标准分类任务中具有更高的精度和更稳定的优化过程。SNN 则需要先将图像转换为




图 23: SNN 在图像 000339 上的输出层 spike count 热力图

脉冲序列，再在多个时间步内进行膜电位更新和脉冲传播，因此训练和推理过程包含额外的时间维度。

尽管 SNN 整体准确率略低于 CNN，但 SNN 提供了 CNN 不具备的时序响应分析方式。隐藏层 spike raster 和输出层 spike count 可以直观反映神经元在不同时间步的发放情况，体现了事件驱动计算的特点。从外部测试结果看，SNN 在 10 张 MNIST-Test 图像上全部预测正确，说明速率编码和 LIF 神经元能够在较简单的灰度图像分类任务中形成有效的类别判别能力。

C. CNN 与 SNN 目标检测对比

在 Pascal VOC 目标检测任务中，CNN 检测模型具有更完整的端到端检测能力，能够同时完成候选区域生成、目标分类和边界框回归，并通过 mAP 指标进行量化评估。相比之下，本文实现的 SNN 检测模型主要承担 ROI 分类任务，候选框位置仍由 CNN 检测器提供。因此，SNN 检测部分更准确地说是在基于 CNN proposal generator 的 SNN 候选区域分类检测框架，而非完全独立的端到端 SNN 检测器。

从工程实现角度看，该设计具有合理性。目标检测中的边界框回归对连续值预测精度要求较高，直接使用 SNN 完成完整检测框回归难度较大；而将 CNN 用于候选框生成、SNN 用于 ROI 分类，可以在保证外部检测流程可运行的同时，展示 SNN 对检测候选区域的脉冲响应。第 3 版 SNN 检测方案通过加入 background 类别、构建正负 proposal 数据集并采用 ANN-to-SNN 蒸馏，提高了外部测试图像上的结果稳定性。

D. 误差来源与局限性

本文实验中的误差主要来自三个方面。首先，MNIST 外部测试中个别样本存在笔画形态模糊或局部结构相似问题，可能导致 CNN 或 SNN 出现类别混淆。其次，Pascal VOC 目标检测图像包含遮挡、小目标、姿态变化和复杂背景，CNN 检测模型可能出现定位偏差、漏检或类别混淆。最后，SNN 检测模型的 ROI 分类准确率受脉冲编码随机性、仿真时间步、类别不平衡和 ROI 裁剪质量影响较大，因此其分类性能低于连续值 CNN 模型。

此外，SNN 检测模型仍依赖 CNN 检测器生成候选框，尚未实现完全端到端的 SNN 目标检测。未来可进一步研究 CNN-to-SNN 检测网络转换、事件相

表 27: 实验开发环境与主要依赖

项目	配置
Python 版本	3.11.15
深度学习框架	PyTorch 2.11.0+cu128
视觉库	torchvision 0.26.0+cu128
SNN 框架	snnTorch 0.9.4
CUDA 软件栈	CUDA Toolkit 12.8.1, cuDNN 9.19
数值计算	NumPy 2.4.4, SciPy 1.17.1, scikit-learn 1.8.0
数据与图像处理	Pandas 3.0.3, Pillow 12.2.0, OpenCV 4.13.0
可视化	Matplotlib 3.10.9
文档编写	Overleaf / L ^A T _E X

机数据输入、脉冲形式的边界框回归以及更高效的神经形态硬件部署方式，以提升 SNN 在复杂视觉检测任务中的实用性。

E. 项目总结

本文完成了 CNN 与 SNN 在图像识别和目标检测任务中的建模、训练、测试和可视化分析。实验结果表明，CNN 在传统静态视觉任务中仍具有精度高、训练稳定和工程成熟的优势；SNN 则能够通过脉冲序列、膜电位动态和 spike count 提供更接近生物神经系统的信息表达方式。两类模型在视觉建模中具有不同侧重点：CNN 更适合高精度静态视觉任务，SNN 在事件驱动计算、稀疏表示和低功耗推理方面具有潜在价值。

VI. 实现与复现说明

A. 开发环境

实验使用 Conda 环境完成，核心解释器版本为 Python 3.11.15。深度学习框架采用 PyTorch 2.11.0+cu128 与 torchvision 0.26.0+cu128，SNN 部分使用 snnTorch 0.9.4 实现 LIF 神经元与速率编码。数据处理和可视化主要依赖 NumPy、Pandas、Pillow、OpenCV、Matplotlib、SciPy 和 scikit-learn。环境文件以 environment.yml 和 requirements.txt 形式导出，便于在相同 CUDA 12.8 软件栈下复现实验。代码中统一设置随机种子，并将模型权重、训练指标、预测结果和可视化图片保存到固定输出目录。

B. 实现流程

项目实现流程由数据准备、模型训练、外部推理和结果整理四个阶段组成。首先下载并整理 MNIST

表 28: 小组成员分工与贡献比例

成员	学号	主要负责内容	贡献比例
刘丰源	12313217	CNN-MNIST、CNN 目标检测、mAP 评估、检测可视化	50%
梁家源	12313215	SNN-MNIST、SNN 目标检测、蒸馏训练、脉冲可视化	50%

和 Pascal VOC 2007 数据集, 构造 MNIST-Test 与 PascalVOC-Test 外部测试目录。随后分别训练 CNN-MNIST、SNN-MNIST、CNN 目标检测模型和 SNN ROI 分类模型。训练完成后, 使用保存的最佳模型对外部测试图像进行推理, 并输出 CSV 结果、预测图像、检测框图和脉冲响应热力图。最后根据实验指标与可视化结果完成对比分析。

C. 项目文件结构

项目采用模块化目录结构, 源代码放置在 `src/` 目录, 数据集放置在 `data/` 目录, 外部测试图像放置在 `external/` 或项目根目录对应测试文件夹中, 实验输出统一保存在 `outputs/` 目录。主要结构如下:

```
project/
+-- data/
|   +-- MNIST/
|   +-- PascalVOC/
+-- external/
|   +-- MNIST-Test/
|   +-- PascalVOC-Test/
+-- outputs/
|   +-- cnn_mnist/
|   +-- snn_mnist/
|   +-- cnn_detection/
|   +-- snn_detection_v1/
|   +-- snn_detection_v2/
|   +-- snn_detection_v3/
+-- src/
|   +-- cnn_mnist/
|   +-- snn_mnist/
|   +-- cnn_detection/
|   +-- snn_detection/
```

D. 小组分工

本项目由两名成员合作完成。刘丰源主要负责 CNN 相关实验, 包括 CNN-MNIST 分类模型、Faster R-CNN 目标检测模型、mAP 评估、外部检测推理和 CNN 结果整理。梁家源主要负责 SNN 相关实验, 包括 SNN-MNIST 分类模型、SNN 目标检测三版迭代、ANN-to-SNN 蒸馏、脉冲响应可视化和 SNN 结果分析。两名成员共同完成实验设计、结果讨论、报告撰写和 PPT 材料整理, 整体贡献比例保持一致。

E. 主要代码与输出文件

主要代码文件如表29所示。CNN 部分包括 MNIST 分类训练、外部图像预测、VOC 数据加载、Faster R-CNN 训练和 mAP 计算; SNN 部分包括 MNIST 脉冲分类、SNN 检测三版迭代、ROI 数据集构建、ANN teacher 训练、SNN 蒸馏训练和外部检测推理。

主要输出文件包括模型权重、指标 JSON、预测

表 29: 主要源代码文件

模块	文件或功能
CNN 图像识别	<code>train.py</code> , <code>predict_external.py</code>
SNN 图像识别	<code>train.py</code> , <code>predict_external.py</code>
CNN 目标检测	<code>train.py</code> , <code>predict_external.py</code> , <code>voc_dataset.py</code> , <code>map_utils.py</code>
SNN 目标检测	V1/V2/V3 ROI 构建、teacher 训练、SNN 蒸馏和外部推理脚本

CSV 和可视化图片, 如表30所示。这些文件共同构成报告中实验结果、曲线图、检测图和 spike 响应图的来源。

表 30: 主要实验输出文件

输出目录	内容
<code>outputs/cnn_mnist/</code>	CNN-MNIST 模型、metrics、loss 曲线和预测图
<code>outputs/snn_mnist/</code>	SNN-MNIST 模型、spike raster、spike count 和预测图
<code>outputs/cnn_detection/</code>	Faster R-CNN 模型、mAP 结果和检测框图
<code>outputs/snn_detection_v1/</code>	第 1 版 SNN 检测训练曲线和外部检测图
<code>outputs/snn_detection_v2/</code>	proposal-matched ROI、ANN teacher 和蒸馏 SNN 结果
<code>outputs/snn_detection_v3/</code>	最终 SNN 检测模型、21 类 ROI 数据集和 spike 热力图

参考文献

- [1] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [2] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]//Advances in Neural Information Processing Systems. 2012: 1097-1105.
- [3] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[C]//Advances in Neural Information Processing Systems. 2015: 91-99.
- [4] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2117-2125.
- [5] Gerstner W, Kistler W M. Spiking Neuron Models: Single Neurons, Populations, Plasticity[M]. Cambridge: Cambridge University Press, 2002.
- [6] Everingham M, Van Gool L, Williams C K I, et al. The PASCAL Visual Object Classes Challenge 2007 (VOC2007) Results[EB/OL]. <http://host.robots.ox.ac.uk/pascal/VOC/voc2007/>.

附录：代码与实验材料

代码与实验材料说明

本文完整代码按照 `src/` 目录下的四个任务模块组织，实验输出统一保存在 `outputs/` 目录。由于正文已经给出关键模型结构、训练参数和实验结果，附录仅列出复现实验所需的主要源代码和输出材料，便于查阅。

表 31: 附件代码文件说明

模块	主要文件与用途
CNN 图像识别	<code>train.py</code> 用于 CNN-MNIST 训练、验证与测试； <code>predict_external.py</code> 用于 MNIST-Test 外部图像预测； <code>export_mnist_test_images.py</code> 用于生成外部测试样本。
SNN 图像识别	<code>train.py</code> 用于 SNN-MNIST 训练与 spike 可视化； <code>predict_external.py</code> 用于 MNIST-Test 外部图像预测。
CNN 目标检测	<code>train.py</code> 用于 Faster R-CNN 训练与 mAP 评估； <code>predict_external.py</code> 用于 PascalVOC-Test 检测可视化； <code>voc_dataset.py</code> 和 <code>map_utils.py</code> 分别用于数据读取和 mAP 计算。
SNN 目标检测	V1 包含 <code>train_roi_snn_v1.py</code> ；V2 包含 <code>build_proposal_roi_dataset_v2.py</code> 、 <code>train_ann_roi_teacher_v2.py</code> 和 <code>train_snn_roi_distill_v2.py</code> ；V3 包含 <code>build_roi_dataset_v3.py</code> 、 <code>train_ann_roi_teacher_v3.py</code> 、 <code>train_snn_roi_distill_v3.py</code> 和 <code>predict_external_v3.py</code> 。

表 32: 附件实验输出说明

输出类型	说明
模型权重	包括 <code>cnn_mnist_best.pt</code> 、 <code>snn_mnist_best.pt</code> 、 <code>cnn_detection_best.pt</code> 和 <code>snn_roi_distill_v3_best.pt</code> 等最佳模型权重。
指标文件	包括 MNIST 分类指标、Pascal VOC 检测 mAP 结果，以及 SNN ROI 蒸馏训练指标，例如 <code>metrics.json</code> 、 <code>map_results.json</code> 和 <code>snn_distill_v3_metrics.json</code> 。
预测结果	包括 MNIST-Test 分类 CSV、PascalVOC-Test 检测 CSV，以及 SNN-v3 外部检测结果 CSV。
可视化图片	包括 loss/accuracy 曲线、MNIST 预测样例、PascalVOC 检测框图、spike raster 图和输出层 spike count 热力图。