

神经网络对视觉识别和检测的建模

CNN 与 SNN 在 MNIST 图像识别和 Pascal VOC 目标检测中的对比实验

刘丰源 (12313217) 梁家源 (12313215)

系统设计与智能制造学院

Southern University of Science and Technology

2026 年 5 月 25 日

答辩内容

- 1 项目问题与总体方案
- 2 MNIST 图像识别
- 3 CNN 目标检测
- 4 SNN 目标检测
- 5 误差分析与总结

解决的问题：视觉识别与目标检测的神经网络建模

任务一：MNIST 图像识别

- 输入：28 × 28 灰度手写数字图像
- 输出：数字 0 ~ 9 分类结果
- 对比：CNN 连续激活与 SNN 脉冲编码
- 指标：测试准确率、外部 10 张图像预测、loss 曲线和 spike 图谱

任务二：Pascal VOC 目标检测

- 输入：真实场景 RGB 图像
- 输出：类别标签与目标框坐标
- CNN：Faster R-CNN 完整检测
- SNN：CNN proposal + ROI 脉冲分类

核心目标：在相同视觉任务上比较 CNN 与 SNN 的精度、效率、误差来源和脉冲响应可解释性。

技术路线与实验步骤



输出材料

- loss 曲线与预测样例
- 外部测试分类列表
- 检测框与类别标签
- spike raster / heatmap

设计原则

以 CNN 建立工程基线；
以 SNN 展示脉冲编码、事件驱动表示和时间动态响应。

CNN-MNIST：结构、训练与分类效果

模型与训练设置



- 结构：Conv-ReLU-Pool $\times 2$ + FC
- 输入： $1 \times 28 \times 28$ ；输出：10 类 logits
- 损失：CrossEntropyLoss
- 优化器：Adam，学习率 10^{-3}
- Epoch：8；Batch size：128
- 参数量：421,642

99.06%

测试集准确率

12.95 s

训练时间



CNN 外部 MNIST-Test: 9/10 正确



模型	官方 Acc	外部正确	主要错误	结论
CNN	99.06%	9/10	5 → 6	✓

关键观察

- 外部 10 张图像中正确识别 9 张，满足至少 8 张正确要求。
- 大部分样本置信度接近 1，说明模型泛化稳定。
- digit_5.png 被误判为 6：下方笔画呈闭合趋势，与数字 6 局部结构相似。

结论：CNN 在外部测试上通过要求，主要误差来自数字 5 与 6 的局部形状相似。

SNN-MNIST: 速率编码 + LIF 神经元

脉冲编码与网络结构



- 速率编码: 像素灰度 $x \in [0, 1]$ 映射为发放概率
- 时间步: $T = 25$, 每张图像转化为脉冲序列
- 结构: 784 输入神经元 $\rightarrow$ 1000 隐藏 LIF $\rightarrow$ 10 输出 LIF
- 分类: 累计输出层 spike count 最大类别
- 独立训练, 不继承 CNN 权重

97.73%


测试集准确率

36.25 s

训练时间



SNN 脉冲活动：可解释的时间动态



结果与解释

- 隐藏层神经元在时间窗内呈现稀疏离散发放。
- 输出层通过 spike count 累计形成分类证据。
- 外部 MNIST-Test: 10/10 正确, digit_5.png 正确识别为 5。

与 CNN 的差异

SNN 引入时间维度和随机脉冲采样, 训练更慢, 但能提供 spike raster 与输出 spike count 等动态可视化。

MNIST 识别结果对比

模型	测试准确率	外部测试	参数量	训练时间	是否达标
CNN	99.06%	9/10	421,642	12.95 s	✓
SNN	97.73%	10/10	795,010	36.25 s	✓

CNN 建模特点

连续激活、空间卷积特征提取稳定，测试准确率和训练效率更高。

SNN 建模特点

速率编码 + LIF 神经元，具有稀疏发放、时间动态和输出 spike 可解释性。

对比结论：CNN 是更强的静态图像识别基线；SNN 略低于 CNN，但达到要求，并提供可观察的脉冲活动证据。

CNN 目标检测: Faster R-CNN MobileNetV3-Large FPN

模型框架

- Backbone: MobileNetV3-Large
- 多尺度特征: FPN
- 第一阶段: RPN 生成候选框
- 第二阶段: RoI Head 分类 + 边界框回归
- 输出类别: VOC 20 类 + background

训练与评价

SGD, 5 epochs, Batch size 4; 评价指标为 Pascal VOC 2007 11-point **mAP@0.5**。

73.95%


最佳 mAP@0.5

297.19 s


总训练时间

Epoch	Train Loss	mAP@0.5
1	0.7512	0.6850
2	0.6087	0.6765
3	0.5646	0.6819
4	0.4794	0.7395
5	0.4726	0.7378


CNN 外部 PascalVOC-Test 检测结果



000258: person 0.99, dog 0.95



000283: 2 person + 2 bicycle




000339: 4 person

结论

Faster R-CNN 能够在自然场景中完成多类别、多实例检测；遮挡与边缘目标会降低置信度并带来定位偏差。

SNN 检测思路: CNN Proposal + SNN ROI



建模取舍

- 完整 SNN 边界框回归难度高，先保留 CNN 的定位优势。
- SNN 专注于候选区域分类，突出脉冲编码和 spike 响应。

结果观察

- 与 CNN 相同外部图像上的检测结果
- ROI 输出层 spike count 热力图
- SNN 检测误差与局限性分析

SNN 检测三版迭代：从可行到稳定

V1: GT Crop

直接训练 20 类 SNN ROI 分类器；训练 ROI 与推理 proposal 分布不一致。



dog → bottle

V2: Proposal-Matched ROI

引入 ANN teacher、ANN-to-SNN 初始化和蒸馏；但缺少 background 类。



dog → cat

V3: Background 过滤

采用 GT crop + 正 proposal + background proposal，扩展为 21 类，最终使用。



dog 正确识别

迭代逻辑：先验证 ROI 脉冲分类可行性，再缩小训练/推理分布差异，最后加入 background 类降低误检。

第 3 版 SNN ROI 分类器：结构与训练



网络结构

- 输入 ROI: $3 \times 64 \times 64$
- Rate coding: $T = 30$
- Conv1/2/3 + LIF + pooling
- AdaptiveAvgPool $\rightarrow$ FC1 + LIF
 $\rightarrow$ FC2 + LIF
- 输出: 21 类 spike count

训练损失

$$L = (1 - \alpha)L_{CE} + \alpha L_{KD} + \lambda L_{mem}$$

$\alpha = 0.75$, 温度 $T_d = 4.0$, $\lambda = 0.10$ 。



第 3 版 SNN 训练结果

指标	数值
ANN teacher 最佳验证准确率	49.94%
ANN teacher 最终非背景准确率	52.79%
SNN 最佳验证准确率	46.62%
SNN 最终验证准确率	46.54%
SNN 最终非背景准确率	47.09%
SNN 训练时间	618.76 s


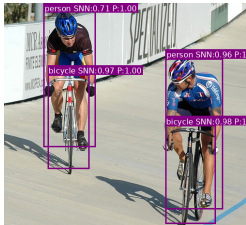
结果解读

Pascal VOC ROI 分类比 MNIST 更复杂：目标尺度、遮挡、背景干扰和类别不均衡明显。

影响因素


速率编码会引入采样随机性和细节损失；SNN ROI 准确率低于 CNN 检测器，但能够输出可解释 spike 响应。

SNN 外部 PascalVOC-Test 检测结果



SNN 保留 CNN 的候选框位置，最终类别由 SNN 输出层平均 spike count 决定；若预测为 background，则过滤该候选框。

输出层 Spike Count 热力图: SNN 的检测证据



读图方法

横轴为 21 个类别，纵轴为不同 ROI；颜色越亮表示输出神经元累计脉冲数越高。person、dog、bicycle 等目标在对应类别形成峰值。

误差分析：主要来源与改进方向

CNN 检测误差

- 定位偏差：遮挡、边缘目标导致预测框不够贴合。
- 实例重叠：骑行者与自行车相互遮挡，NMS 和候选框筛选更敏感。
- 类别混淆：dog/cat、bicycle/motorbike 等形状或纹理相近类别易混淆。

SNN 检测局限

- ROI 分类依赖 CNN proposal，尚未端到端完成边界框回归。
- 速率编码会损失部分连续图像细节，并引入采样随机性。
- Pascal VOC 类别复杂且不均衡，SNN ROI 分类难度较高。

改进方向：MNIST 可针对 5/6 等相似笔画增加数据增强；检测任务可采用更稳定的脉冲编码、更长/自适应时间窗、类别重采样和端到端 SNN 检测头。

项目结果汇总

任务	模型	核心指标	外部测试结果	是否满足要求
MNIST 图像识别	CNN	Acc = 99.06%	9/10	✓
MNIST 图像识别	SNN	Acc = 97.73%	10/10	✓
Pascal VOC 目标检测	CNN	mAP@0.5 = 73.95%	3 张检测图	✓
Pascal VOC 目标检测	SNN	ROI Acc = 46.62%	3 张检测图 + spike 图	✓

CNN：高精度、训练稳定、目标检测工程适用性强。

SNN：事件驱动、脉冲稀疏、可输出神经元动态响应。

队员任务分工

成员	学号	主要负责内容	贡献比例
刘丰源	12313217	CNN-MNIST、CNN 目标检测、mAP 评估、检测可视化及 CNN 相关报告整理	50%
梁家源	12313215	SNN-MNIST、SNN 目标检测三版迭代、spike 可视化及 SNN 相关报告整理	50%

共同完成

任务需求拆解、实验结果对比、误差分析、报告撰写、答辩材料整理和最终检查。

总结

- 完成 CNN 与 SNN 在 **MNIST 图像识别** 和 **Pascal VOC 目标检测** 中的建模与实验对比。
- CNN 在分类准确率、检测 mAP 和训练效率上表现更优，是静态视觉任务的强基准。
- SNN 通过速率编码和 LIF 神经元实现图像分类与 ROI 检测分类，并输出 spike raster、spike count 热力图等动态证据。
- SNN 目标检测采用三版迭代，最终通过 proposal-matched ROI、ANN-to-SNN 蒸馏和 background 过滤提升外部检测稳定性。

核心结论：CNN 更适合当前工程精度需求；SNN 在事件驱动表示、脉冲可解释性和神经形态计算方向具有继续研究价值。

Thanks!

欢迎老师和同学提问

神经网络对视觉识别和检测的建模

刘丰源 梁家源